بسم الله الرحمن الرحيم پروژه پاياني درس پردازش زبانهاي طبيعي

پروژه پیشنهادی

موضوع: سیستم پرسش و پاسخ چند زبانه در ارتباط با داروها بر اساس جستجو در متون پزشکی			
کاربرد و اهمیت مساله: اطلاع از اطلاعات و تحقیقات مرتبط با حوزه دارو و پزشکی، پیادهسازی یه سیستم پرسش و پاسخ پزشکی به زبان فارسی			
https://pubmed.ncbi.nlm.nih.gov/download/ https://physionet.org/files/mimiciii/1.4/		دادگان مورد استفاده	
خروجی: پاسخ پرسش با زبان وارد شده مثال: - ترجمه و خلاصه شده مطالب مرتبط با سوال براساس مجموعه دادگان	ورودی: یک پرسش به زبان دلخواه مثال: - داروهای مرتبط با سرطان سینه - استفاده از داروی چه عوارضی دارد؟	ورودی و خروجیهای مساله	
- Retrieval (self annotation): بر اساس یک مجموعه ی حدودا 20 تایی از سوالات و چکیده مقالات مرتبط با آن ها (که به علت ارتباطشان باید مدل بتواند آن ها را بازیابی کند). Final answer (based on datasets, and annotation) بر اساس سوالات و پاسخ های نهایی آماده موجود (توضیح انواع ممکن در بخش MultiMedQA معیار ارزیابی): داده های MultiMedQA		داده ارزیابی	
- Retrieval (self annotation): mean reciprocal rank - Final answer (based on datasets, and annotation): برای پاسخ های بله/خیر یا هرگونه پاسخ قابل تقسیم بندی به چند دسته از دقت و سایر معیارهای مرسوم میتوان استفاده نمود. برای پاسخ های تشریحی و بلند میتوان از سنجش انسانی یا LLM ها برای مقایسه میزان شباهت پاسخ درست و پاسخ نهایی استفاده نمود.		معیار ارزیابی	
 بردن متن سوال به فضای زبان انگلیسی براساس مدل زبانی مثلا 		مدل پیشنهادی	

LaBSE یا ChatGPT، انجام vector search برروی منابع مورد استفاده، خلاصه سازی و بهبود خروجی به کمک LLM ها و ترجمه به زبان مقصد	
دو مدل برای مقایسه با مدل نهایی پیادهسازی شده در نظر گرفته شده است که شامل یک مدل پایه و یک مدل transformer است تا هرچه بهتر بتوانیم مدل خود را ارزیابی کنیم: - Fasttext Cross-lingual - BERT	مدلهای پایه برای مقایسه
- ساختن خروجي با استفاده از مهندسي پرامپت	مساله توليد متن
- تولید خروجی متنی و ترجمه	استفاده از مدلهای زبانی بزرگ
۔ یک واسط کاربری جستوجوی وب و یا در هاگینگفیس	دمو پیشنهادی
 Translation of the question to one semantic space Developing a retrieval-based QA Evaluation of the model's retrieval based on manual annotations Text generation/translation using prompt engineering Evaluation of final answer 	مراحل پیشنهادی